

Доменная адаптация русскоязычного ModernBERT для анализа нормативно-правовых текстов

Аннотация

Предложена модель RuModernBERT-ruLaw для обработки длинных русскоязычных нормативно-правовых документов. Модель получена продолженным предобучением энкодера RuModernBERT-base на 304 382 документах корпуса RusLawOD, содержащих 194 425 905 токенов. Максимальная длина контекста равна 8192 токенам. Обучение выполнено на одном узле кластера НИЯУ МИФИ с восемью ускорителями NVIDIA A100 40 ГБ. На внешней коллекции судебных решений проведено парное сравнение при пяти реализациях случайного маскирования. Средняя перплексия уменьшилась с 1,6711 до 1,5633, то есть на 6,45%; 95%-й доверительный интервал для относительного уменьшения равен [6,13; 6,78]%. Дополнительно исследовано распознавание именованных сущностей на дедуплицированном разбиении без пересечения текстов. Исходная и адаптированная модели достигли близких значений F_1 : 0,99852 и 0,99820 соответственно; дополнительное MLM-предобучение не улучшило NER.

Ключевые слова: обработка естественного языка, юридические тексты, ModernBERT, продолженное предобучение, masked language modeling, распознавание именованных сущностей.

1. Введение

Нормативно-правовые документы имеют устойчивую специальную лексику, формализованную структуру и дальние ссылочные зависимости. Поэтому при их обработке существенны одновременно доменная адаптация и длинный контекст. Архитектура ModernBERT сочетает двунаправленное представление BERT [1] с контекстом до 8192 токенов и чередованием глобального и локального внимания [2].

В работе исследуется продолженное предобучение русскоязычного ModernBERT на корпусе нормативных актов RusLawOD [3]. Вклад работы состоит в следующем: (1) описана воспроизводимая схема распределённого продолженного предобучения длинноконтекстного энкодера; (2) эффект доменной адаптации проверен на внешней коллекции судебных решений при одинаковых реализациях случайного маскирования; (3) перенос на распознавание сущностей оценён на разбиении, исключающем точные дубликаты и конфликтующие примеры.

2. Модель и метод обучения

2.1. Продолженное MLM-предобучение

Исходной моделью служила deepvk/RuModernBERT-base. После фильтрации корпус сохранил $D = 304\,382$ документа и $N = 194\,425\,905$ токенов. Для окна $W = (x_1, \dots, x_L)$, $L \leq 8192$, случайно выбиралось множество маскируемых позиций M с вероятностью включения $p = 0,15$. Минимизировалась отрицательная логарифмическая правдоподобность

$$\mathcal{L}_{\text{MLM}}(\theta; W, M) = -\frac{1}{|M|} \sum_{i \in M} \log p_{\theta}(x_i \mid W_{\setminus M}). \quad (1)$$

Перплексия определялась как

$$\text{PPL}(\theta) = \exp\left(\frac{1}{K} \sum_{k=1}^K \mathcal{L}_{\text{MLM}}(\theta; W_k, M_k)\right). \quad (2)$$

В ModernBERT локальное внимание с шириной окна w требует $O(Lw)$ операций и памяти для матрицы внимания, тогда как глобальное внимание требует $O(L^2)$. Чередование этих слоёв позволяет сохранять глобальный обмен информацией, не оплачивая квадратичную стоимость во всех слоях.

2.2. Распознавание сущностей

Каждому токenu назначалась BIO-метка $z_t \in \mathcal{C}$. Для множества Ω первых подтокоенов размеченных слов минимизировалась функция

$$\mathcal{L}_{\text{NER}}(\phi) = -\frac{1}{|\Omega|} \sum_{t \in \Omega} \log p_{\phi}(z_t | W). \quad (3)$$

Документы токенизировались с максимальной длиной 8192 и перекрытием 1024 токена. Качество измерялось на уровне сущностей:

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}. \quad (4)$$

Исходные 97 668 строк группировались по SHA-256 нормализованного текста. Из данных удалены 15 783 повторные строки и 109 строк, относящихся к 32 текстам с конфликтующими метками. Оставшиеся 81 776 уникальных примеров детерминированно разделены по хешу текста на обучающую, валидационную и тестовую части объёмом 65 382, 8 133 и 8 261 соответственно. Попарное пересечение множеств нормализованных текстов равно нулю.

3. Вычислительный эксперимент

Эксперименты проведены на одном узле кластера НИЯУ МИФИ: два процессора AMD EPYC 7542, 512 ГиБ оперативной памяти и восемь NVIDIA A100 PCIe с 40 ГиБ памяти. Используются Python 3.11.15, PyTorch 2.6.0 с CUDA 12.4, Transformers 4.57.3 и DeepSpeed 0.19.1.

Продолженное предобучение выполнялось в BF16 с FlashAttention-2 [4] и DeepSpeed ZeRO-2 [5]. При четырёх последовательностях на GPU и одном шаге накопления градиента глобальный пакет составлял

$$B_{\text{global}} = N_{\text{GPU}} B_{\text{device}} A = 8 \cdot 4 \cdot 1 = 32, \quad (5)$$

или не более $32 \cdot 8192 = 262\,144$ токен-позиций за шаг оптимизатора. Применялся AdamW [6] с начальной скоростью $7 \cdot 10^{-5}$. Из запланированных 20 эпох ранняя остановка сработала после приблизительно 16,38 эпохи; минимальная валидационная потеря 0,133617 достигнута на шаге 200 000.

NER-модели обучались три эпохи с глобальным пакетом 8 и скоростью $3 \cdot 10^{-5}$. Для честного сравнения исходный и адаптированный энкодеры обучались на одном и том же очищенном разбиении с одинаковыми гиперпараметрами.

Внешняя MLM-выборка содержала $K = 1031$ фрагмент судебных решений. Для каждого seed $s \in \{11, 23, 42, 67, 101\}$ обе модели оценивались на одной реализации масок. Пусть $d_s = \mathcal{L}_{\text{base},s} - \mathcal{L}_{\text{law},s}$. При $n = 5$ доверительный интервал строился по парным разностям:

$$\bar{d} \pm t_{0,975;n-1} \frac{s_d}{\sqrt{n}}, \quad t_{0,975;4} = 2,776. \quad (6)$$

4. Результаты

Таблица 1: MLM-потеря и перплексия на внешней выборке

Seed	$\mathcal{L}_{\text{base}}$	$\mathcal{L}_{\text{law}}$	PPL_{base}	PPL_{law}
11	0,51672	0,44903	1,67652	1,56680
23	0,50854	0,44592	1,66286	1,56192
42	0,51754	0,44831	1,67789	1,56566
67	0,50924	0,44417	1,66403	1,55919
101	0,51547	0,44657	1,67443	1,56295
Среднее	0,51350	0,44680	1,67115	1,56330

Во всех пяти парных опытах доменно адаптированная модель превосходит исходную. Средняя разность потерь равна $\bar{d} = 0,06670$ при $s_d = 0,00281$; по формуле (6) получен 95%-й интервал $[0,06322; 0,07018]$. Для каждого seed вычислялось относительное уменьшение

$$r_s = 1 - \frac{\text{PPL}_{\text{law},s}}{\text{PPL}_{\text{base},s}} = 1 - \exp(-d_s). \quad (7)$$

Среднее $\bar{r} = 0,06452$, а 95%-й t-интервал равен $[0,06126; 0,06778]$. Таким образом, снижение перплексии составляет 6,45% и устойчиво к реализации случайного маскирования.

Таблица 2: Результаты NER на очищенной тестовой части

Энкодер	Precision	Recall	F_1
RuModernBERT-base	0,99841	0,99863	0,99852
RuModernBERT-ruLaw	0,99794	0,99846	0,99820

Тестовые потери исходной и адаптированной моделей практически совпали: $6,58 \cdot 10^{-5}$ и $6,57 \cdot 10^{-5}$. При этом исходная модель получила $F_1 = 0,99852$, а адаптированная — $F_1 = 0,99820$; разность $-0,00032$ не свидетельствует об улучшении NER. Высокие значения нельзя объяснить точными копиями между частями данных: дедупликация выполнена до разбиения, а тексты трёх частей не пересекаются. Следовательно, доказанный эффект доменной адаптации относится к MLM на юридическом тексте, но не переносится автоматически на эту задачу распознавания сущностей.

5. Заключение

Продолженное MLM-предобучение русскоязычного ModernBERT на нормативных актах даёт воспроизводимое улучшение на внешней коллекции судебных решений. Парный эксперимент с пятью реализациями маскирования показал уменьшение перплексии на 6,45% с узким доверительным интервалом. На очищенной NER-выборке обе модели достигли $F_1 > 0,998$, однако адаптация не дала улучшения относительно исходного энкодера. Тем самым результат подтверждает доменный выигрыш в языковом моделировании, но показывает необходимость отдельной проверки переноса для каждой прикладной задачи. Модель и код экспериментов опубликованы открыто [7, 8].

Благодарности

Вычисления выполнены с использованием оборудования высокопроизводительного вычислительного кластера НИЯУ МИФИ.

Соблюдение этических стандартов

Конфликт интересов. Авторы заявляют об отсутствии конфликта интересов.

Список литературы

- [1] Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proc. NAACL-HLT. 2019. P. 4171–4186. DOI: 10.18653/v1/N19-1423.
- [2] Warner B. et al. Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference. 2024. arXiv:2412.13663.
- [3] Saveliev D., Kuchakov R. The Russian Legislative Corpus. 2024. arXiv:2406.04855.
- [4] Dao T. FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning. 2023. arXiv:2307.08691.
- [5] Rajbhandari S., Rasley J., Ruwase O., He Y. ZeRO: Memory Optimizations Toward Training Trillion Parameter Models // Proc. SC20. 2020. DOI: 10.1109/SC41405.2020.00024.
- [6] Loshchilov I., Hutter F. Decoupled Weight Decay Regularization // Proc. ICLR. 2019.
- [7] TryDotAtwo. RuModernBERT-ruLaw: model card. <https://huggingface.co/TryDotAtwo/RuModernBERT-ruLaw> (дата обращения: 29.07.2026).
- [8] TryDotAtwo. RuModernBERT-ruLaw: исходный код и сценарии экспериментов. <https://github.com/TryDotAtwo/RuModernBERT-ruLaw> (дата обращения: 29.07.2026).

DOMAIN ADAPTATION OF RUSSIAN MODERNBERT FOR LEGAL DOCUMENT ANALYSIS

Abstract. We present RuModernBERT-ruLaw, a Russian-language encoder for long legal documents. It was obtained by continued masked-language-model pretraining of RuModernBERT-base on 304,382 documents of the RusLawOD corpus with a maximum context length of 8192 tokens. Training used a single NRNU MEPhI cluster node with eight NVIDIA A100 40 GB GPUs. In a paired evaluation with five random masking seeds on an external collection of court decisions, mean perplexity decreased from 1.6711 to 1.5633, a relative reduction of 6.45% with a 95% confidence interval of [6.13%, 6.78%]. On a deduplicated named-entity recognition split with no exact text overlap, the base and adapted models achieved $F_1 = 0.99852$ and $F_1 = 0.99820$, respectively; continued pretraining did not improve NER.

Keywords: natural language processing, legal text, ModernBERT, continued pretraining, masked language modeling, named entity recognition.